

CAT 를 넘어 LAT 로: LLM 번역 검수를 위한 인터페이스 Co-design Beyond CAT to LAT: Co-designing Interfaces for LLM-Based Machine Translation Post-Editing (MTPE)

김정환

Junghwan Kim

서울대학교

지능정보융합학과

Department of Intelligence
and Information

Seoul National University
jhbale11@snu.ac.kr

서봉원

Bongwon Suh

서울대학교

지능정보융합학과

Department of Intelligence
and Information

Seoul National University
bongwon@snu.ac.kr

ABSTRACT

대규모 언어 모델(LLM)은 번역 품질을 혁신하였으며, GPT와 Claude 등은 최신 WMT 평가에서 인간 수준의 성능을 입증하였다. 이에 따라 번역 산업의 중심축은 기계번역 후편집(Machine Translation Post-Editing, MTPE)으로 빠르게 이동하고 있다. 그러나 1990 년대에 설계된 기존 컴퓨터 보조 번역(Computer-Aided Translation, CAT) 도구는 세그먼트(문장) 단위의 분절적 패러다임을 따르고 있어, 장문 컨텍스트 유지와 창의적 재구성을 특징으로 하는 LLM 번역을 효과적으로 지원하지 못한다. 본 연구는 이러한 한계를 극복하기 위해 LLM 보조 번역(LLM-Assisted Translation, LAT)이라는 새로운 인터페이스 패러다임을 제안한다. 3-10 년 경력의 번역 전문가 5 명과 개별 Co-design 세션을 통해 도출된 가이드라인을 기반으로, 자동 정렬 알고리즘과 양방향 상호작용 기능을 포함한 프로토타입을 구현 및 평가하였다. 연구 결과, 참여자들은 명시적 정렬 시각화를 통해 문장 탐색 인지 부하가 현저히 감소했음을 확인하였다. 또한 검수 과정이 순차적 오류 수정에서 전체적 맥락을 조율하는 협업적 디렉팅으로 전환되는 경험적 변화를 보고하였다. 본 연구는 LLM 시대에 적합한 번역 검수 인터페이스의 실증적 디자인 가이드라인과 기술적 구현 가능성을 제시한다.

KEYWORDS

LLM Translation, Machine Translation Post-Editing, Computer-Aided Translation, Co-design Research, LLM-Assisted Translation

1 INTRODUCTION

대규모 언어 모델(Large Language Model, LLM)의 등장은 번역 산업의 지형을 근본적으로 변화시켰다. GPT-4와 Claude 같은 최신 LLM은 2024년 WMT 평가에서 9개 언어 쌍 최고 성능을 기록하며, 기존의 신경망 기계번역(Neural Machine Translation, NMT) 수준을 크게 상회하였다[7]. 특히 문맥 이해, 창의적 표현, 문화적 뉘앙스 포착 능력에서의 비약적인 발전은 번역 워크플로우의 중심축을 '번역(Translation)'에서 '검수 및 개선', 즉 기계번역 후편집(Machine Translation Post-Editing, MTPE)으로 빠르게 이동시키고 있다.

그러나 LLM 번역의 탁월함에도 불구하고, 출판급 품질을 위한 전문가의 개입은 여전히 필수적이다. LLM은 원문에 없는 내용을 사실처럼 생성하는 환각(Hallucination) 현상을 빈번히 일으키며, 장편 콘텐츠 번역 시 용어와 스타일의 일관성(Consistency)을 유지하는 데 취약점을 보인다. 특히 의미는 왜곡되었으나 문법적으로는 자연스러운 '유창한 오역'은 발견하기 어려워, 법률이나 기술 문서 등에서 심각한 위험 요소가 될 수 있다. 따라서 인간 전문가에 의한 정밀한 MTPE는 LLM 시대에도 대체 불가능한 핵심 단계로 남아있다.

문제는 현재 업계 표준인 컴퓨터 보조 번역(Computer-Aided Translation, CAT) 도구들이 LLM 번역의 특성을 전혀 반영하지 못한다는 점이다. SDL Trados나 MemoQ와 같은 기존 도구들은 1990-2000 년대에 정립된 세그먼트(Segment) 중심 패러다임을 따른다. 이는 문장을 독립적인 단위로 분절하고 원문과 번역문의 1:1

대응을 가정하는 방식으로, 규칙 기반 번역이나 초기 NMT에는 적합했다. 하지만 수천 단어의 맥락을 고려하여 문장을 자유롭게 병합·분리하고 재구성하는 LLM의 청크(Chunk) 기반 번역과는 근본적인 불일치를 일으킨다.

본 연구는 이러한 도구적 한계가 실제 번역 현장에서 심각한 비효율을 초래한다는 문제의식에서 출발하였다. 웹소설 번역 실무에서 기존 CAT 도구는 LLM의 긴 호흡을 담아내지 못했고, 검수자들은 텍스트 에디터에서 수동으로 스크롤을 조절하며 문장 짝을 찾는 데 전체 작업 시간의 상당 부분을 허비해야 했다. 이에 본 연구는 기존의 세그먼트 중심 CAT를 넘어선, LLM 보조 번역(LLM-Assisted Translation, 이하 LAT)이라는 새로운 인터페이스 패러다임의 필요성을 제기한다.

이를 구체화하기 위해 본 연구는 사용자 중심 설계(User-Centered Design) 접근을 채택하였다. 5명의 MTPE 전문가와 심층적인 Co-design 세션을 수행하여 그들의 암묵적인 고충과 니즈를 명시적인 디자인 지식으로 전환하였으며, 이를 바탕으로 실제 작동하는 프로토타입을 개발 및 평가하였다. 본 연구가 탐구하고자 하는 핵심 연구 질문(Research Questions)은 다음과 같다.

[RQ1] LLM 기반 번역 검수 과정에서 전문가들이 겪는 구조적 페인 포인트(Pain Points)는 무엇인가?

[RQ2] LLM 번역의 특성을 반영한 효과적인 LAT 인터페이스 디자인 원칙은 무엇인가?

본 연구는 LLM 시대 번역 검수의 특수성을 실무자 관점에서 규명하고, 실증 기반의 디자인 가이드라인을 제시한다. 나아가 프로토타입 평가를 통해 검수 패러다임이 단순 '오류 수정'에서 AI를 지휘하는 '창의적 디렉팅(Creative Directing)'으로 전환되는 양상을 포착함으로써, 향후 Human-AI 협업 번역 도구가 나아가야 할 방향성을 제시한다.

2 RELATED WORKS

2.1 Machine Translation Post-Editing(MTPE)

MTPE 연구는 주로 인지 부하 측정과 생산성 분석에 집중해왔다. Carl 등[1]의 시선 추적 연구는 MT 품질이 낮을수록 검수자의 고정 시간과 재방문이 증가함을 보였다. Lacruz 등[2]은 키스트로크 로깅을 통해 복잡한 오류일수록 검수자가 더 오래 멈춰 생각하고 여러 번 수정을 시도한다는 것을 발견했다. Daems 등[3]에 따르면 의미 오류는 문법 오류보다 수정 시간이 3배 이상 길며, 이는 원문과 번역문을 세심하게 대조해야 하기 때문이다.

MTPE 인터페이스 개선 시도도 있었다. Herbig 등[4]은 펜, 터치, 음성을 통합한 멀티모달 인터페이스 MMPE를 제안했으나, 참여자들은 새로운 모달리티를 마우스와 키보드의 확장으로 여겼다. Lefer 등[5]은 번역 교육용 앱을 개발하여 표준화된 품질 평가를 지원했다.

그러나 기존 연구 대부분은 통계 기반 MT나 초기 NMT를 대상으로 했다. 통계 기반 MT는 주로 문법적 오류와 어색한 단어 선택 문제를 보이며, 이러한 오류는 번역문만 보아도 명백하다. Zouhar 등[6]의 최근 연구는 30명 이상의 전문 번역가를 대상으로 NMT 품질과 후편집 시간의 관계를 조사하였으나, BLEU가 시간이나 최종 품질의 안정적 예측 변수가 아니라는 것을 발견하였다. 반면 LLM은 문법적으로 완벽하지만 환각, 누락, 일관성 부족 같은 오류들을 포함한다. 기존 CAT 도구는 세그먼트 중심 패러다임으로 설계되어 LLM 번역의 장문 컨텍스트, 창의적 재구성, 맥락 의존성을 지원하지 못한다.

2.2 LLM Translation : Capabilities and Challenges

LLM의 번역 능력 평가는 최근 활발히 진행되고 있다. 2024년 WMT 평가에서 Claude 3.5-Sonnet은 11개 언어 쌍 중 9개에서 최고 성능을 기록했고, GPT-4는 5개 언어 쌍에서 가장 좋은 성능을 달성했다[7]. 이는 범용 LLM이 특화된 NMT 시스템을 능가할 수 있음을 보여준다. Hendy 등[8]은 GPT 모델이 고자원 언어에서는 인간 수준에 근접하지만 저자원 언어에서는 한계가 있음을 밝혔다.

그러나 LLM 번역에는 고유한 문제들이 존재한다. 환각은 가장 특징적인 오류로, LLM이 원문에 없는 내용을 자신감 있게 추가하는 경우가 빈번하다. Thai 등[10]의 문학 번역 연구에서 전문 번역가들은 인간 번역을 84% 선호했으며, MT 출력물이 단순 오역뿐 아니라 담화를 방해하는 오류와 스타일 비일관성을 포함한다고 지적했다. 장편 콘텐츠에서 같은 용어나 캐릭터 이름이 챕터마다 다르게 번역되는 일관성 부족도 중요한 문제다.

문서 수준 번역도 도전 과제다. Wang 등[11]은 긴 텍스트에서 일관성과 결속성 유지가 어렵다는 것을 확인했다. Peng 등[13]은 ChatGPT를 번역에 활용하는 방법을 탐구했으나 프롬프팅 전략에만 초점을 맞췄다. 본 연구는 이러한 LLM 번역의 특성과 한계를 고려하여 전문가가 효과적으로 검수할 수 있는 인터페이스 설계에 집중한다.

2.3 Co-design and Participatory Approaches in HCI

Participatory Design(PD)은 최종 사용자를 디자인 프로세스의 적극적 파트너로 참여시키는 접근이다. Sanders와 Stappers[15]는 co-creation 도구와 워크샵 방법론을 발전시켰으며, 사용자가 디자인을 함께 창조하는 역할을 강조했다. Lee 등[17]은 지난 10 년간 185 편의 PD 논문을 분석하여 HCI 연구에서 PD 가 디자인 공간 탐구, 새로운 솔루션 개발, 개념적 프레이밍 확장의 세 가지 목적으로 사용된다는 것을 발견했다.

전문가 도구 설계에서 PD 의 가치는 특히 두드러진다. 전문가들은 자신의 작업에 대한 깊은 이해를 가지지만 이 지식은 대부분 암묵적이다. Ericsson 과 Simon[18]에 따르면 전문가는 패턴 인식과 청킹을 통해 복잡한 문제를 효율적으로 해결하지만 이러한 인지 과정을 표현하기 어렵다. PD 는 참여자들이 함께 작업하고 토론하는 과정에서 암묵지를 명시화하고, 개별 경험을 집단 지식으로 전환한다.

Human-AI 협업 연구는 자동화 수준 설정의 중요성을 강조한다. Parasuraman 등[19]의 적응적 자동화 이론은 자동화 수준이 작업 복잡도와 시스템 신뢰도에 따라 동적으로 조정되어야 한다고 주장한다. 그러나 번역 도구 설계에서 PD 접근은 거의 시도되지 않았다. 본 연구는 번역 전문가들을 co-design 파트너로 참여시켜 LLM 시대 검수 인터페이스를 공동 설계한 최초의 시도다.

3 METHOD

3.1 Participants

5 명의 PE 전문가를 모집하였다. 참여 기준은 (1) 최소 3 년 번역 및 Post Editing 경력, (3) 다양한 도메인 커버리지였다. P1 은 3 년 경력의 웹소설 번역가(한영), P2 는 7 년 경력의 소설 번역가(영한), P3 는 5 년 경력의 문학 번역가(한영), P4 는 10 년 경력의 마케팅 번역가(영한), P5 는 8 년 경력의 게임/컨텐츠 번역가(한일)이다. 연구 시작 전 모든 참여자의 서면 동의를 받았다.

Table 1 Participants Demographics

ID	Gender	Age	Years	Language Pair
P1	F	29	3	한-영 (Kr-En)
P2	F	34	7	한-영 (Kr-En)
P3	M	31	5	한-영 (Kr-En)
P4	F	41	10	한-영 (Kr-En)
P5	F	36	8	한-일(Kr-Jp)

3.2 Phase 1 : Individual Co-design Sessions

각 참여자와 1 시간의 개별 co-design 세션을 진행하였다. 연구자와 연구보조자(퍼실리테이터, 노트테이커), 참여자 1 명이 조용한 미팅룸에서 대면으로 만났다.

첫 30 분은 need-finding 으로, 반구조화 인터뷰를 통해 최근 LLM 번역 검수 경험을 탐구하였다. 평소 검수 도구와 방법, 가장 시간이 많이 걸리는 부분, 어렵거나 좌절스러운 순간, 현재 도구의 한계 등을 질문하였다. 연구자가 핵심 pain points 를 포스트잇에 기록한 후, 15 분간 화이트보드에 붙이고 참여자와 함께 그룹화하였다. 평균 8-12 개의 pain points 가 3-5 개 클러스터로 정리되었고, 가장 시급한 문제 3 개를 선택하였다.

후반 30 분은 solution sketching 으로, 선택된 문제에 대해 해결책을 함께 스케치하였다. 퍼실리테이터가 참여자의 설명을 바탕으로 화이트보드에 초안을 그리면, 참여자가 직접 수정하거나 다시 그리는 방식으로 아이디어를 구체화하였다. 각 문제당 2-3 개의 아이디어 스케치가 생성되었다. 마지막 10 분간 생성된 아이디어를 함께 검토하며 Must-have 와 Nice-to-have 를 구분하고 우선순위를 표시하였다. 전체 세션을 녹화·전사하였으며 포스트잇과 스케치를 수집하였다.

3.3 Phase 2 : Design Synthesis and Prototyping

Phase 1 완료 후 2 주간 연구팀이 데이터를 통합 분석하고 프로토타입을 개발하였다. 5 명의 전사본(총 약 120 페이지)을 Braun 과 Clarke 의 주제 분석 방법으로 코딩하여 89 개 초기 코드를 생성하고, 이를 그룹화하여 17 개 잠재 테마를 도출하였다. 수렴 분석에 주목하여 5 명 중 몇 명이 동일한 pain point 나 솔루션을 언급했는지 정량화하였다. 3 명 이상이 언급한 것만 주요 테마로 선정하여 공통 패턴을 포착하였다.

참여자들의 스케치를 체계적으로 분석하여 유사한 아이디어를 그룹화하고 반복되는 디자인 요소를 추출하였다. 참여자들이 부여한 우선순위를 집계하여 Must-have 기능을 결정하였다. 수렴 분석 결과를 바탕으로 5 개 디자인 원칙과 12 개 가이드라인을 도출하였다.




Figure 1 본 연구의 전체 연구 프로세스 개요.

이를 기반으로 React 기반 웹 인터페이스 프로토타입을 개발하였다(Figure 2). Google Gemini API를 실제 연동하여 주요 기능을 구현하였다.

(A) **Chunk-based Navigation**은 문장 단위가 아닌 의미 단위의 문단으로 콘텐츠를 구분하고 진행률을 표시하여 검수자가 전체 맥락을 파악하며 작업하도록 돕는다.

(B) **Sync-Highlighting & Alignment**은 LLM 번역에서 빈번히 발생하는 문장 병합 및 분리, 그리고 누락 문제를 해결하기 위해, 단순 유사도 계산 대신 LLM 기반의 구조적 정렬 에이전트를 도입하였다. 구체적으로, 확정된 번역문의 문단 레이아웃을 기준점으로 삼아, LLM에게 원문을 해당 구조에 맞춰 1:1로 대응되도록 재분할할 것을 지시하는 구조적 프롬프팅 기법을 적용하였다. 이 과정에서 프롬프트는 단순히 텍스트를 나누는 것을 넘어, 번역문에 반영되지 않은 미매칭 구간을 식별하고 그 위치 정보를 JSON 형식의 구조화된 데이터로 반환하도록 설계되었다. 이를 통해 N:M 매핑 상황이나 번역 누락이 발생한 경우에도 정확한 대응 관계를 시각화할 수 있는 정밀한 정렬 시스템을 구현하였다.

(C) **AI-Assisted Verification**은 AI가 탐지한 스타일 문제, 오역, 누락 등에 대해 신뢰도 점수와 함께 구체적인 수정 제안을 제시하여 검수자의 의사결정을 보조한다.

(D) **Re-translation Request**는 현재 청크의 번역 품질이 낮거나 다른 스타일이 필요한 경우 사용자가 즉시 LLM에게 재번역을 요청할 수 있는 양방향 협업 기능을 제공한다. 이 외에도 커스텀 인스트럭션, 버전 비교 뷰, 전역 검색 등을 구현하였다.

3.4 Phase 3 : Prototype Testing

각 참여자와 30분의 개별 테스트 세션을 진행하였다. Phase 1과 동일한 5명이 참여하였다. 처음 5분간 프로토타입의 주요 기능을 간단히 시연하였다. 이어서 참여자 도메인에 맞는 2,000단어 콘텐츠를 제공하여 Full Post-Editing 수준으로 검수를 수행하도록 하였다.

20분간 think-aloud 프로토콜을 사용하여 참여자가 작업하면서 머릿속 생각을 말로 표현하도록 요청하였다. 연구자는 필요시 "지금 무엇을 하려고 하시나요?", "이 기능은 어떠신가요?", "Phase 1에서 사용하던 방식과 비교하면?" 같은 프로브 질문을 하였다. 화면을 녹화하고 발화를 기록하였으며, 원문-번역문 전환 횟수, 하이라이트 기능 사용 빈도, 재번역 사용 여부, 긍정적/부정적 반응 등을 관찰하였다.

마지막 5분간 비교 인터뷰를 진행하였다. 전반적 경험, Phase 1 방식과의 비교, 가장 도움이 된 기능, 여전히 불편한 점, 실제 업무 사용 의향 등을 질문하였다. 특히 "이전에는 문장 찾는 데 얼마나 걸렸는데 지금은?"와 같은 직접적 비교 질문을 통해 변화를 구체화하였다.

3.5 Data Analysis

Phase 1 데이터는 주제 분석과 수렴 분석으로 처리하였다. 전사본 120페이지를 Braun과 Clarke의 6단계 프로세스[24]로 코딩하여 89개 초기 코드에서 5개 주요 테마를 도출하였다. 5명 중 몇 명이 동일 pain point를 언급했는지 정량화하여 3명 이상 언급한 것만 주요 패턴으로 인정하였다.

Phase 3 데이터는 비교 분석으로 처리하였다. Phase 1 vs Phase 3 비교 발언을 추출하고 "이전에는... 지금은..." 패턴을 코딩하였다. 긍정 반응("오!", "좋다", "편하네")과 부정 반응("어?", "이상하다")을 태그하였다. 원문-번역문 전환 횟수, 문장 대응 찾기 소요 시간, 재번역 사용 횟수, 기능별 사용 빈도 등 정량적 데이터도 수집하였다.

Table 2 Design Principles and Guidelines for LLM Post-Editing Interface

Principles	Guidelines	Description
Principle 1	GL 1 Bilateral View	원문과 번역문을 좌우 대칭으로 배치하여 시선의 이동을 최소화하고 직관적인 비교를 지원한다.
Explicit Alignment Visualization (명시적 정렬 시각화)	GL 2 Auto-Alignment	LLM 에 의해 병합되거나 분리된 문장 간의 대응 관계를 자동으로 계산하여 시각적으로 연결한다.
	GL 3 Sync-Highlighting	마우스 커서나 캐럿의 위치에 따라 대응되는 원문/번역문 구간을 실시간으로 동기화하여 하이라이트한다.
Principle 2	GL 4 Chunk-based Navigation	문장 단위가 아닌 문단(Chunk) 단위의 네비게이션을 제공하여 전체 맥락 파악을 용이하게 한다.
Context-Aware Interface (맥락 인지 인터페이스)	GL 5 Context Preview	현재 작업 중인 구간의 이전/이후 문맥을 흐름 끊김 없이 확인할 수 있는 미리보기 기능을 제공한다.
	GL 6 Progress Visualization	전체 문서 내에서의 현재 위치와 검수 진행률을 직관적인 시각적 지표로 제공한다.
Principle 3	GL 7 Re-translation	특정 구간에 대해 LLM 에게 즉시 재번역을 요청할 수 있는 버튼 및 인터랙션을 제공한다.
Bidirectional Collaboration (양방향 협업)	GL 8 Custom Prompts	톤앤매너 조정이나 특정 용어 사용 등 구체적인 수정 지시사항(프롬프트)을 입력할 수 있게 한다.
	GL 9 Version Comparison	LLM 이 생성한 여러 번역 대안을 비교하고 최적의 결과를 선택할 수 있는 뷰를 제공한다.
Principle 4	GL 10 Auto-QA	오역, 누락, 환각 등이 의심되는 구간을 AI 가 자동으로 탐지하여 경고(Alert)를 표시한다.
AI-Assisted Verification (AI 보조 검증)	GL 11 Confidence Score	번역문의 정확도에 대한 AI 의 신뢰도 점수를 시각화하여 검수자가 주의 깊게 봐야 할 곳을 안내한다.
Principle 5		
Project-wide Consistency (전역 일관성 관리)	GL 12 Global Search	문서 전체 또는 프로젝트 전반에 걸친 용어 검색 및 일괄 변경 기능을 제공하여 일관성을 유지한다.

4 FINDINGS

4.1 Converging Pain Points from Individual Sessions

5 명의 독립적 co-design 세션에서 강력하게 수렴하는 pain points 가 발견되었다. 가장 보편적 문제는 **정렬 가시성(Alignment Visibility)**으로, 5 명 전원이 문장 대응 찾기를 최우선 과제로 꼽았다. P1 은 "검수 시간의 절반은 그냥 문장 찾기에요. LLM 이 세 문장을 하나로 합치면 어디가 어딘지 완전히 헤매요"라고 설명하였다. P3 는 "그 단어가 영어 어디에 나왔는지 찾는 데만 5 분씩 걸린다"고 하였다. 솔루션으로 5 명 전원이 양면 뷰를, 4 명이 자동 정렬 선을, 3 명이 클릭-하이라이트 인터랙션을 제안하였다.

두 번째 주요 과제는 **컨텍스트 단편화(Context Fragmentation)**로 4 명이 언급하였다. P1 은 "캐릭터가 앞에서 어떻게 말했는지 확인하려면 스크롤을 계속 올렸다 내렸다 한다"고 하였다. 세 번째는 **재번역 장벽(Re-translation Barrier)**으로 4 명이 강하게 요청하였다. P2 는 "직접 GPT 가서 복사-붙여넣기하고 다시 와야 하는" 번거로움을, P4 는 "좀 더 캐주얼하게 LLM 한테 말할 방법이 없다"는 불편함을 토로하였다. 이러한 수렴 패턴은 LLM 번역 검수의 구조적 과제임을 시사한다.

4.2 Five Design Principles and Twelve Guidelines

교차 분석을 통해 5 개 디자인 원칙과 12 개 구체적 가이드라인을 도출하였다.




Figure 2 디자인 가이드라인이 적용된 LAT(LLM-Assisted Translation) 프로토타입 인터페이스.

Principle 1: Explicit Alignment Visualization은 원문과 번역문의 대응을 명확히 시각화해야 함을 강조한다. 여기에는 양면 뷰(GL-1, 5/5 Must-have), 자동 문장 정렬 계산(GL-2, 4/5), 커서 동기화 하이라이트(GL-3, 3/5)가 포함된다. P1은 "나란히만 보여줘도 검수가 두 배는 빨라질 것"이라고 하였고, P5는 "클릭 한 번으로 대응이 보이면 완벽하다"고 평가하였다.

Principle 2: Context-Aware Interface는 충분한 맥락을 유지하며 작업할 수 있어야 함을 의미한다. 청크 기반 검수 뷰(GL-4, 5/5), 컨텍스트 미리보기(GL-5, 2/5), 진행 상태 가시화(GL-6, 3/5)가 이에 해당한다. P1은 "문단 단위로 봐야 이야기를 이해한다"고 강조하였다.

Principle 3: Bidirectional Collaboration은 검수자와 LLM의 양방향 소통을 지원한다. 재번역 실행(GL-7, 4/5 Must-have), 커스텀 인스트럭션(GL-8, 3/5), 버전 비교(GL-9, 4/5)가 포함되며, P2는 "이 기능만 있어도 효율이 엄청 오를 것"이라고 평가하였다.

Principle 4: AI-Assisted Verification은 AI가 품질 평가를 보조하되 최종 판단은 인간이 함을 원칙으로 한다. 자동 품질 평가(GL-10, 2/5 Should-have)와 신뢰도 표시(GL-11, 5/5 조건부 동의)가 이에 해당한다. P3는 "신뢰도를 보고 우선순위를 정하겠다"고 하였다.

Principle 5: Project-Wide Consistency는 프로젝트 전역의 일관성 관리를 지원하며, 전역 검색(GL-12, 3/5 Should-have)이 핵심이다. P1은 "장편에서는 필수"라고 강조하였다.

4.3 Prototype Testing: Observed Behavioral Changes

프로토타입 평가 결과, 5명의 참여자 모두에게서 세 가지 주요한 행동 변화가 관찰되었다.

첫째, 문장 대응 탐색에 소요되는 인지적, 물리적 비용이 극적으로 감소하였다. P1은 "기존에는 한 문장 확인에 10-20초가 소요되었으나, 지금은 시각적 동기화 덕분에 1-2초 내에 즉각적 인지가 가능합니다"라고 언급하였으며, P3는 "탐색 비용이 사라지자 비로소 텍스트의 품질 자체에 집중할 수 있게 되었습니다"라고 평가하였다. 화면 녹화 분석 결과, Phase 1 대비 원문-번역문 간 시선 교차 및 스크롤 조작 빈도가 현저히 줄어들었으며, 참여자들은 2,000 단어 기준 검수 시간이 약 70% 이상 단축될 것으로 추산하였다.

둘째, 검수 패러다임이 기존의 '문장 단위 순차 비교'에서 '문단 단위 전체적 독해 후 선별적 검증'으로 구조적 전환을 이루었다. P1은 "완전히 다른 경험"이라며 "이제 저는 영어를 쭉 읽어요. 마치 독자처럼요"라고 표현하였다. 이는 검수자가 번역문의 전반적인 흐름과 맥락을 먼저 파악하고, 의심스러운 부분에 한해서만 원문과 대조하는 효율적인 작업 방식으로의 전환을 의미한다.

셋째, LLM과의 관계가 단순 수정에서 능동적 협업으로 변화하였다. 4명의 참여자가 재번역 기능을 적극 활용하며 "LLM과 대화하는 느낌"이라고 평가하였고, P4는 "과거의 수동적 교정에서 벗어나 LLM을 지휘하는 주체가 되었다"며 효능감을 표했다. 테스트 종료 후 5명 전원이 실제 업무 도입 의향을 밝히며 긍정적인 반응을 보였다.

5 DISCUSSION

5.1 Individual Co-design as a Pragmatic Method for Expert Tools

본 연구는 개별 co-design 세션이 전문가 도구 설계에서 그룹 워크샵 대비 세 가지 측면에서 실용적임을 보여준다. 첫째는 실행 가능성으로, 바쁜 전문가들의 일정을 고려할 때 다수 참여가 필요한 그룹 세션은 조율이 불가능했으나 1.5 시간의 개별 참여는 현실적이었다. 둘째는 깊이로, 1:1 상호작용은 P3의 문학적 특수성이나 P4의 톤 조정 니즈와 같은 개별 맥락을 그룹 역학의 방해 없이 심층적으로 탐구할 수 있게 해주었다. 셋째는 수렴 증거의 강건함으로, 집단 사고의 편향 없이 5명 전원이 독립적으로 정렬 가시성을 최우선으로 꼽은 것은 이것이 구조적 과제를 강력히 입증한다. 다만 그룹 워크샵의 집단 창의성과 상호 학습 효과도 존재하므로, 향후에는 개별 탐구와 그룹 브레인스토밍을 결합하는 하이브리드 접근이 가장 효과적일 것이다.

5.2 Co-sketching as a Bridge from Tacit to Explicit Knowledge

참여자들 처음 pain points를 언급할 때는 추상적이고 모호했다. 그러나 함께 스케치하는 과정에서 암묵지가 명시적 디자인 지식으로 전환되었다. 말로만 설명하면 연구자와 참여자가 다르게 이해할 수 있으나, 종이에 그리면 "아니요, 이게 아니라 이거예요"라며 즉각 수정할 수 있다. 특히 연구자가 먼저 참여자의 설명을 바탕으로 초안을 스케치하고 참여자가 이를 수정하는 방식이 효과적이었다. 참여자가 백지에서 그리는 것은 심리적 장벽이 있으나, 연구자의 초안을 비판하고 개선하는 것은 훨씬 쉽다. P2의 경우 처음에는 "문장 찾기가 어렵다"는 모호한 표현만 했으나, 연구자가 간단한 박스 두 개를 그리자 즉시 "여기에 선으로 연결하고, 클릭하면 하이лай트"라며 구체적인 하이лай트 인터랙션을 설명하며 암묵지를 표출하였다.

5.3 Paradigm Shift: From Error Correction to Creative Direction

프로토타입 테스트 결과는 MTPE 패러다임이 근본적으로 전환되고 있음을 시사한다. 첫째, 기존 CAT의 문장별 순차 확인 제약에서 벗어나, 양면 뷰와 커서 동기화를 통해 번역문 전체를 먼저 이해하고 필요한 부분만 원문과 대조하는 전체적 접근으로 변화하였다. 둘째, 재번역 기능을 통해 검수자는 단순히 결과를 수정하는 것을 넘

어, P4가 "LLM을 지휘한다"고 표현한 것처럼 수정 방향을 지시하고 최적안을 선택하는 능동적 역할을 수행하게 되었다. 셋째, 오류 수정자에서 창의적 디렉터로의 역할 재정의이다. 문법 오류 수정보다 전체 흐름, 톤, 스타일을 평가하고 개선하는 고차원적 편집 작업이 중심이 된다. 미래의 번역 전문가는 단순히 두 언어를 아는 것을 넘어, AI와 효과적으로 협업하며 전체적 품질을 관리하는 능력을 갖추어야 한다.

5.4 Limitations and Future Directions

본 연구는 LLM 번역 검수 인터페이스의 디자인 가능성을 탐색한 초기 연구로서 몇 가지 한계를 지닌다.

첫째, 표본의 크기와 일반화의 한계다. 5명의 전문가는 심층적인 인사이트를 제공하기에 충분하였으나, 통계적 유의성을 담보하기에는 부족하다. 향후 연구에서는 30명 이상의 대규모 표본을 대상으로 하여 본 연구에서 도출된 가이드라인의 일반 타당성을 검증해야 할 것이다.

둘째, 정량적 성능 평가의 부재다. 본 연구는 프로토타입을 활용한 30분 간의 단기 세션을 통해 사용자의 경험적 변화를 포착하는 데 주력하였다. 따라서 실제 업무 환경에서의 생산성(WPM, Words Per Minute) 향상이나 최종 번역 품질(BLEU, TER 등)의 변화를 정량적으로 측정하지 못했다는 한계가 있다. 후속 연구에서는 기존 CAT 툴과 제안된 LAT 인터페이스 간의 A/B 테스트를 통해, 실제 번역 속도와 품질, 그리고 피로도 저감 효과를 정량적으로 입증하는 종단적 연구가 요구된다.

6 CONCLUSION

본 연구는 5명의 번역 전문가와의 Co-design을 통해, 기존 세그먼트 중심의 CAT 도구가 LLM 시대의 번역 검수에 부적합함을 규명하고, 이를 해결하기 위한 5대 디자인 원칙과 12개 가이드라인을 도출하였다. 특히 자동 정렬과 맥락 인지 기능을 구현한 프로토타입 평가는 번역가의 역할이 단순 교정자(Corrector)에서 AI와 협업하는 창의적 디렉터(Creative Director)로 진화할 수 있음을 실증적으로 보여주었다. 비록 소규모 탐색적 연구라는 한계가 있으나, 본 연구는 암묵지에 머물러 있던 전문가의 니즈를 명시적 시스템 요구사항으로 전환하고, CAT에서 LAT로의 불가피한 전환을 이끌어낼 구체적인 청사진을 제시했다는 점에서 의의를 갖는다. 향후 본 연구가 제시한 가이드라인이 실제 상용 도구 개발과 후속 정량 연구의 견고한 토대가 되기를 기대한다.

ACKNOWLEDGMENT

This work was partly supported by Institute of Information & Communications Technology Planning & Evaluation (IITP) grant funded by the Korea government(MSIT) [NO.RS-2021-II211343, ArtificialIntelligence Graduate School Program (Seoul National University)] and Basic Science Research Program through the National ResearchFoundation of Korea (NRF) funded by the Ministry of Education(No. RS-2025-25421701)

참고문헌

- [1] Carl, M., Dragsted, B., Elming, J., Hardt, D., & Jakobsen, A. L. The Process of Post-Editing: A Pilot Study. *Copenhagen Studies in Language*. 41. Samfundslitteratur. 131-142. 2011.
- [2] Lacruz, I., Shreve, G. M., & Angelone, E. Average Pause Ratio as an Indicator of Cognitive Effort in Post-Editing: A Case Study. *Proceedings of the 10th Conference of the Association for Machine Translation in the Americas (AMTA 2012)*. San Diego, CA. 2012.
- [3] Daems, J., Vandepitte, S., Hartsuiker, R. J., & Macken, L. Translation Methods and Experience: A Comparative Analysis of Human Translation and Post-Editing with Students and Professional Translators. *Meta: Translators' Journal*. 62(2). Les Presses de l'Université de Montréal. 245-270. 2017.
- [4] Herbig, N., Düwel, T., Pal, S., Meladaki, K., Monshizadeh, M., Krüger, A., & van Genabith, J. MMPE: A Multi-Modal Interface for Post-Editing Machine Translation. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL 2020)*. Association for Computational Linguistics. 1691-1702. 2020.
- [5] Lefer, M., Bodart, R., Piette, J., & Obrušník, A. MTPE quality evaluation in translator education: the postedit.me app. *Proceedings of the 25th Annual Conference of the European Association for Machine Translation (EAMT 2024)*. Sheffield, UK. 23-24. 2024.
- [6] Zouhar, V., Popel, M., Bojar, O., & Tamchyna, A. Neural Machine Translation Quality and Post-Editing Performance. *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP 2021)*. Association for Computational Linguistics. 10204-10214. 2021.
- [7] Tom, K., Kocmi, T., Bawden, R., Bojar, O., Dvorkovich, A., Federmann, C., Fishel, M., Freitag, M., Graham, Y., et al. Findings of the 2024 Conference on Machine Translation (WMT24): LLMs Are Here but Not Quite There Yet. *Proceedings of the Ninth Conference on Machine Translation (WMT 2024)*. Association for Computational Linguistics. 2024.
- [8] Hendy, A., Abdelrehim, M., Sharaf, A., Raunak, V., Gabr, M., Matsushita, H., Kim, Y. J., Afify, M., & Awadalla, H. H. How Good Are GPT Models at Machine Translation? A Comprehensive Evaluation. *arXiv preprint arXiv:2302.09210*. 2023.
- [9] Enis, M., & Hopkins, M. From LLM to NMT: Advancing Low-Resource Machine Translation with Claude. *arXiv preprint arXiv:2404.13813*. 2024.
- [10] Thai, K., Karpinska, M., Krishna, K., Ray, B., Inghilleri, M., Wieting, J., & Iyyer, M. Exploring Document-Level Literary Machine Translation with Parallel Paragraphs from World Literature. *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP 2022)*. Association for Computational Linguistics. 9882-9902. 2022.
- [11] Wang, L., Zhang, Z., Chen, J., Huang, S., & Tu, Z. Rethinking Document-Level Neural Machine Translation. *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL 2022)*. Association for Computational Linguistics. 3537-3548. 2022.
- [12] Voita, E., Sennrich, R., & Titov, I. When a Good Translation is Wrong in Context: Context-Aware Machine Translation Improves on Deixis, Ellipsis, and Lexical Cohesion. *Proceedings of the 57th Annual Meeting of the*

Association for Computational Linguistics (ACL 2019). Association for Computational Linguistics, 1198–1212. 2019.

[13] Peng, K., Ding, L., Zhong, Q., Shen, L., Liu, X., Zhang, M., Ouyang, Y., & Tao, D. Towards Making the Most of ChatGPT for Machine Translation. Findings of the Association for Computational Linguistics: EMNLP 2023. Association for Computational Linguistics, 5622–5633. 2023.

[14] Huang, H., Wu, S., Liang, X., Wang, B., Shi, Y., Wu, P., Yang, M., & Zhao, T. Towards Making the Most of LLM for Translation Quality Estimation. Proceedings of CCF International Conference on Natural Language Processing and Chinese Computing (NLP&CC 2023). Springer, 375–386. 2023.

[15] Sanders, E. B., & Stappers, P. J. Co-creation and the New Landscapes of Design. *CoDesign*, 4(1). Taylor & Francis, 5–18. 2008.

[16] Muller, M. J. Participatory Design: The Third Space in HCI. In Jacko, J. & Sears, A. (Eds.). *The Human-Computer Interaction Handbook*. Lawrence Erlbaum Associates, 1051–1068. 2002.

[17] Lee, J., Kim, H., & Park, S. Participatory Design in Human-Computer Interaction: Cases, Characteristics, and Lessons. Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems (CHI 2025). ACM, 2025.

[18] Ericsson, K. A., & Simon, H. A. *Protocol Analysis: Verbal Reports as Data* (Revised Edition). Cambridge, MA: MIT Press, 1993.

[19] Parasuraman, R., Sheridan, T. B., & Wickens, C. D. A Model for Types and Levels of Human Interaction with Automation. *IEEE Transactions on Systems, Man, and Cybernetics – Part A: Systems and Humans*, 30(3). IEEE, 286–297. 2000.

[20] Horvitz, E. Principles of Mixed-Initiative User Interfaces. Proceedings of the SIGCHI Conference on Human Factors in Computing Systems (CHI 1999). ACM, 159–166. 1999.

[21] Guerberoof-Arenas, A. Correlations between Productivity and Quality when Post-Editing in a Professional Context. *Machine Translation*, 28(3–4). Springer, 165–186. 2014.

[22] Brown, T., Guzmán, R., & Irani, L. Co-design Partners as Transformative Learners: Imagining Ideal Technology for Schools by Centering Speculative Relationships. Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems (CHI 2024). ACM, 2024.

[23] Polanyi, M. *The Tacit Dimension*. Chicago: University of Chicago Press, 1966.

[24] Braun, V. and Clarke, V., Using thematic analysis in psychology. *Qualitative research in psychology*, 3(2), pp.77–101. 2006.